Fundamentos de Aprendizaje de Máquina

PhD Jorge Rudas

INFOTEP
INSTITUCIÓN DE
EDUCACIÓN
SUPERIOR

https://github.com/jrudascas/ml-infotep

- Ejercicio del día
- Exposiciones
- Noticias de actualidad
- Introducció a la depuración de datos

```python
a = "Jorge Rudas"

b = {}

for c in a:
    if c in b:
        b[c] += 1
    else:
        b[c] = 1

print(b)
```

- **Unsupervised learning**
- **Supervised learning**
- Probabilistic
- Non-Probabilistic
- Reinforcement learning
- Generative AI

*“**Supervised learning** models can make predictions after seeing lots of data with the correct answers and then discovering the connections between the elements in the data that produce the correct answers. This is like a student learning new material by studying old exams that contain both questions and answers. Once the student has trained on enough old exams, the student is well prepared to take a new exam. These ML systems are "supervised" in the sense that a human gives the ML system data with the known correct results”*

Google AI Team

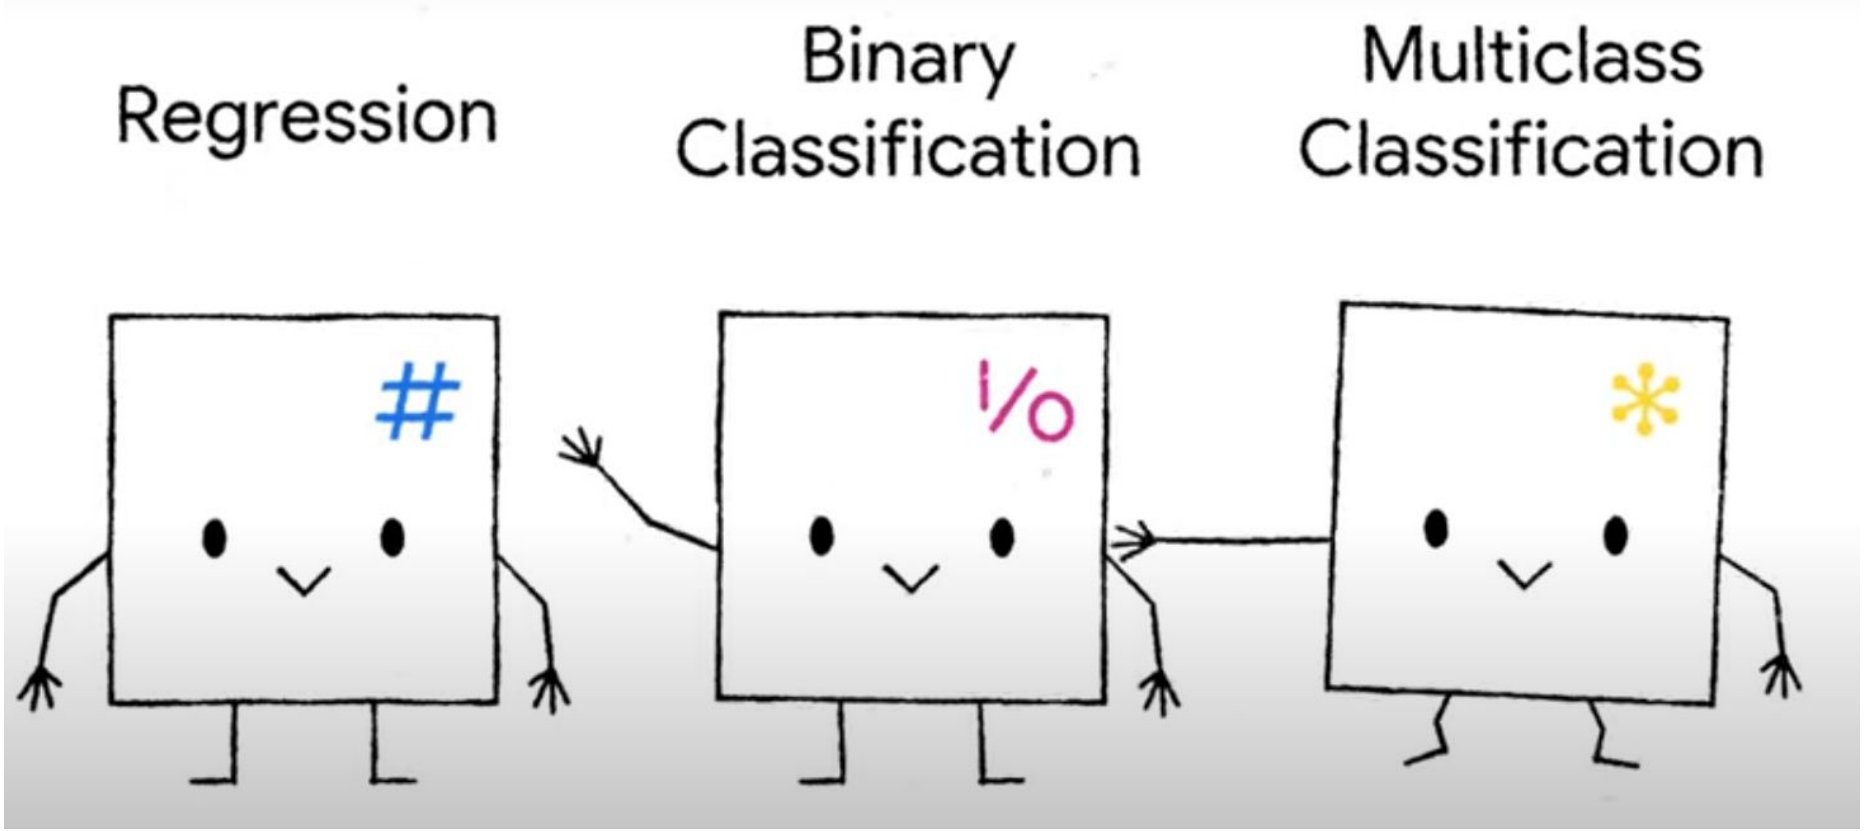
Regression
Binary Classification
Multiclass Classification
#
1/0
*

Thinkstock

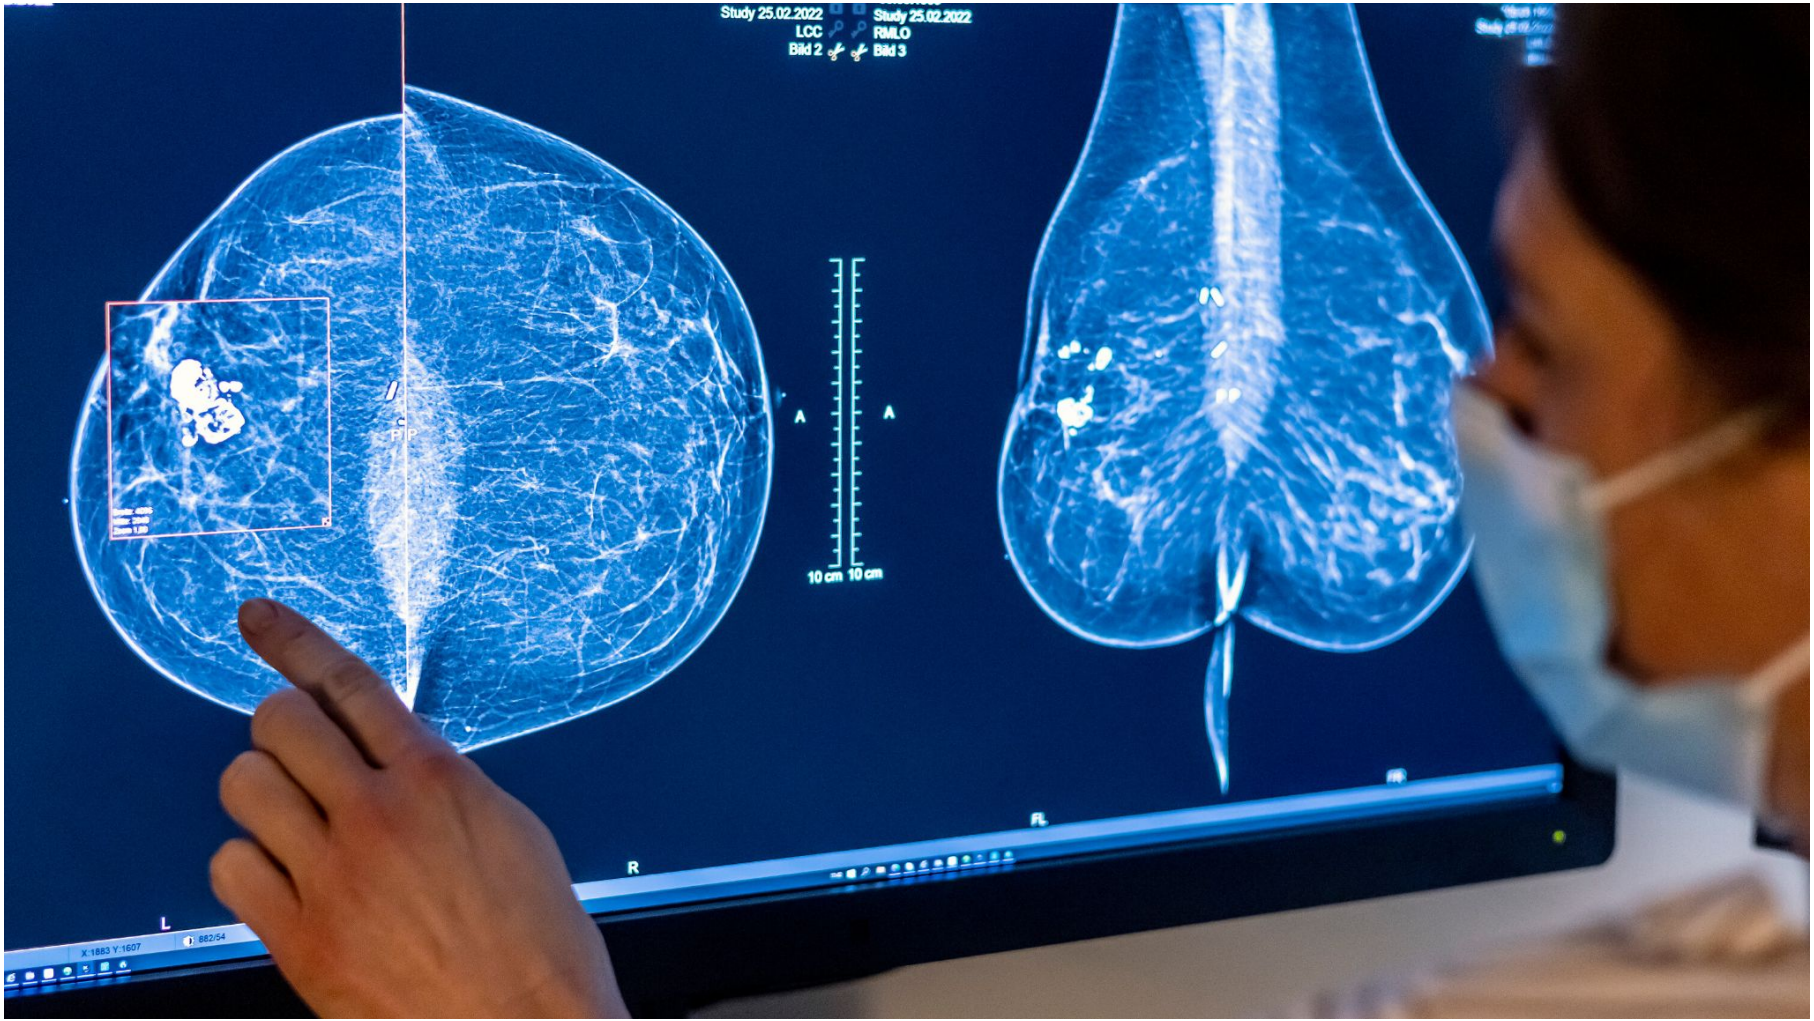
Study 25.02.2022
LCC
Bild 2
Study 25.02.2022
RMLO
Bild 3
A
A
10 cm
10 cm
R
L

*“**Unsupervised learning** models make predictions by being given data that does not contain any correct answers. An unsupervised learning model's goal is to identify meaningful patterns among the data. In other words, the model has no hints on how to categorize each piece of data, but instead it must infer its own rules.”*

Google AI Team

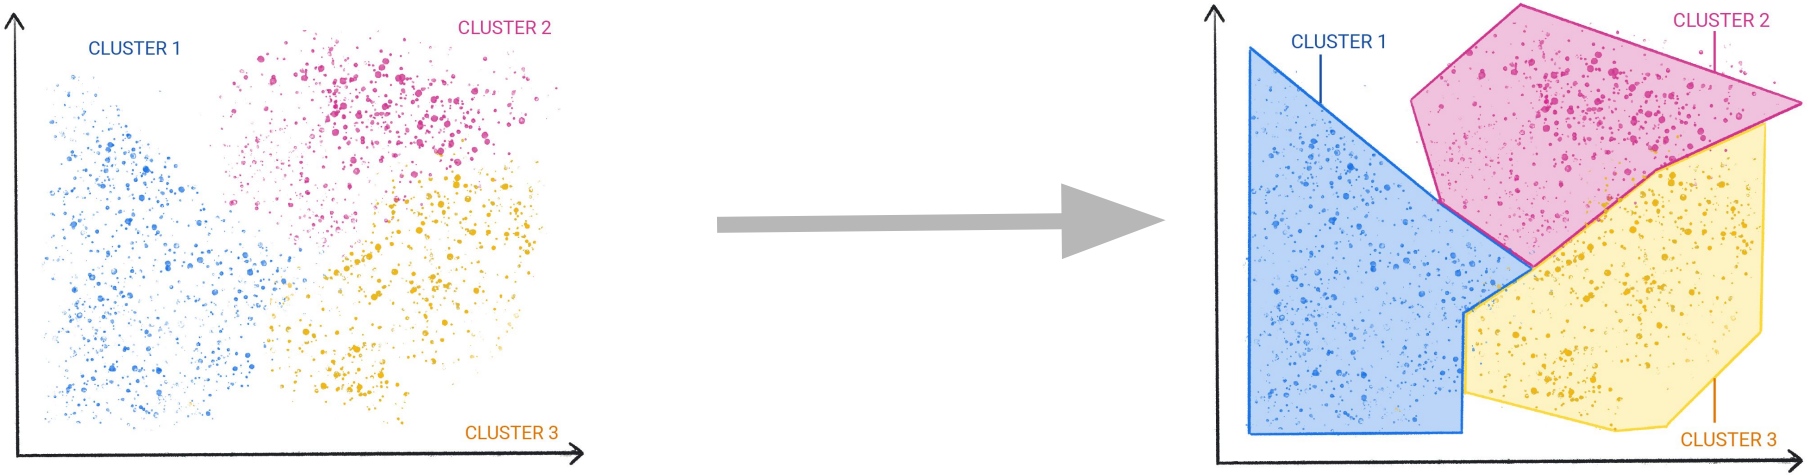
CLUSTER 1
CLUSTER 2
CLUSTER 3
CLUSTER 1
CLUSTER 2
CLUSTER 3

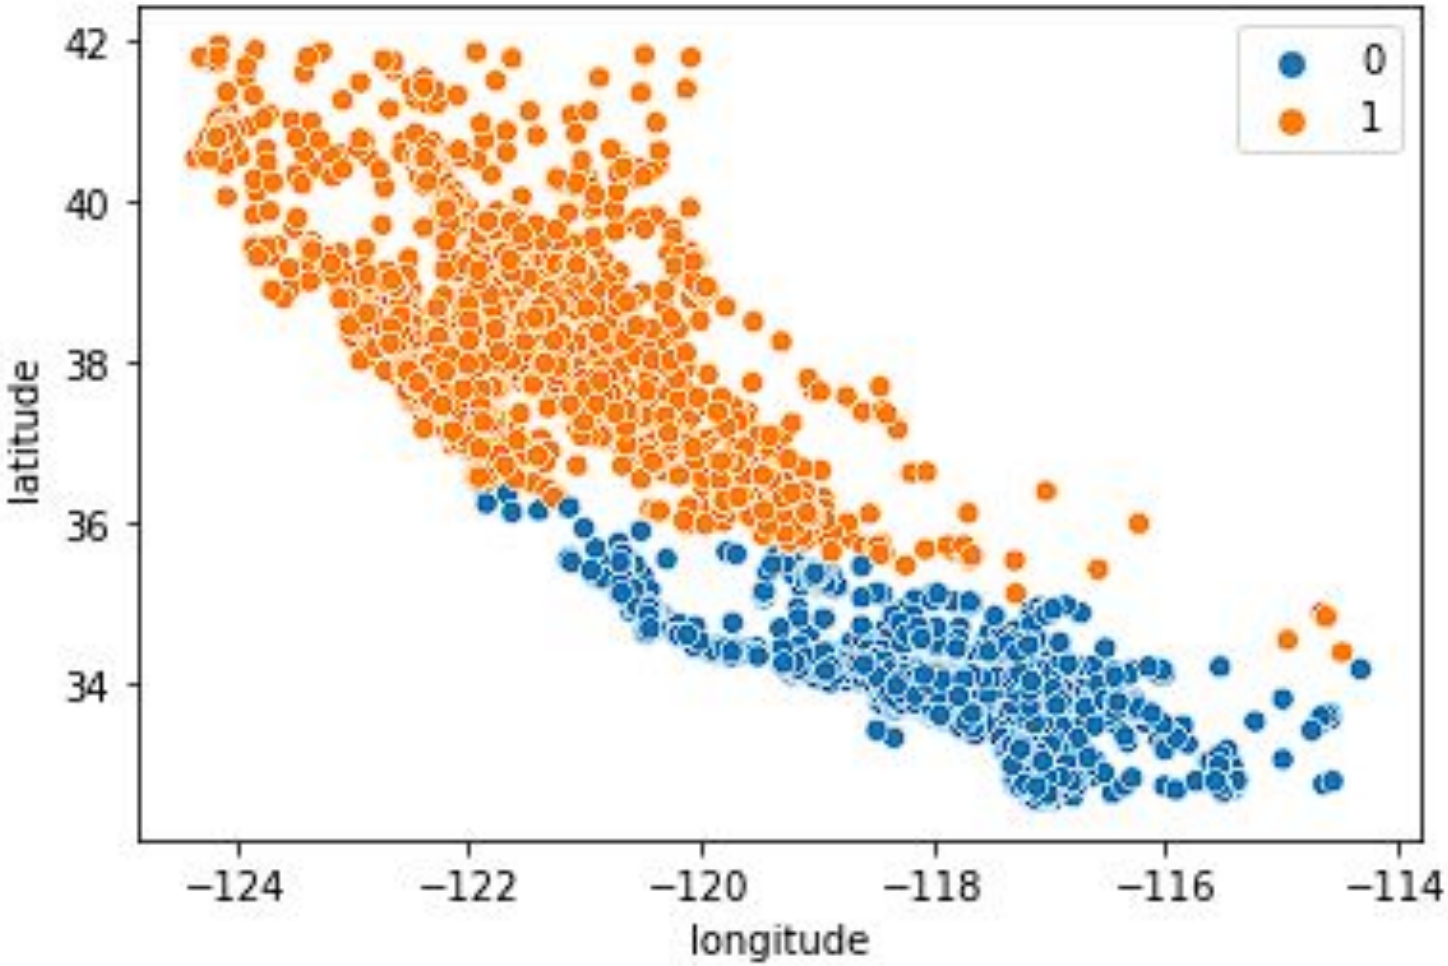
0
1
42
40
38
36
34
latitude
−124
−122
−120
−118
−116
−114
longitude

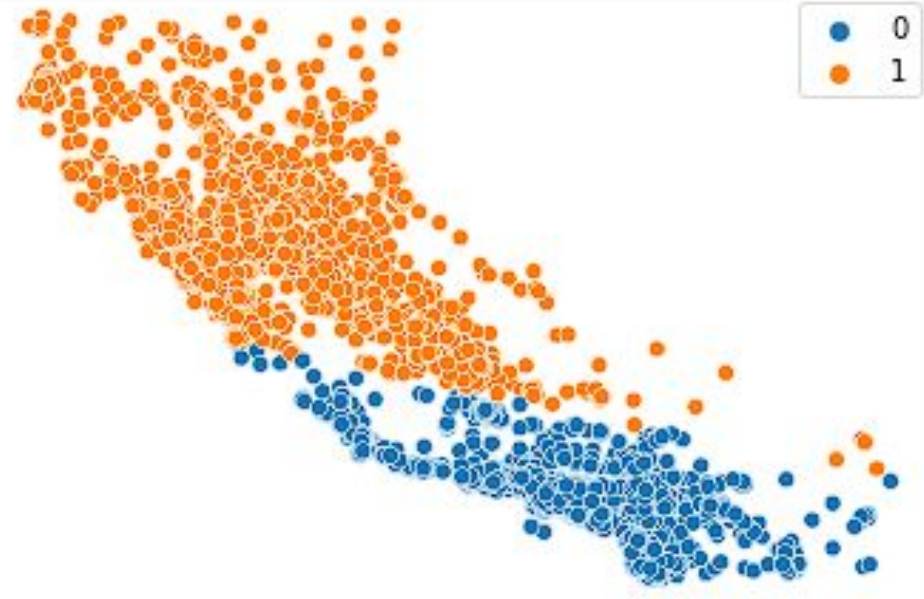

1. x → Edad
   y → Calificaciones promedio en el programa de Ingeniería Informática
   Colegio Privado - **Colegio Público**

2. x → Edad
   y → Investigaciones abiertas en la procuraduría
   Partido Político A - **Partido Político B**

3. x → Longitud
   y → Latitud
   Reporte de homicidio - **Reporte de riñas**

Taller individual

Baloto®

Taller grupal

Dataset: synthetic_dataset.csv

Actividades

- Investigar que es la calidad de un dataset, que aspectos son evaluables y que herramientas están disponibles en lenguaje de programación python para este propósito.

- Con lo anteriormente investigado, define una métrica de calidad de datos

- Defina un algoritmo para pre procesar sus datos:
  - Datos vacíos
  - Datos duplicados
  - Datos atípicos o anómalos
  - Normalización de datos
  - Gestión de datos categóricos

Referencia de apoyo

- https://www.deployr.ai/2024/02/06/una-introduccion-a-herramientas-de-data-quality-en-python/
- https://medium.com/womenintechnology/data-preprocessing-steps-for-machine-learning-in-phyton-part-1-18009c6f1153
- https://www.purestorage.com/es/knowledge/what-is-data-preprocessing.html#:~:text=El%20preprocesamiento%20de%20datos%20para%20el%20aprendizaje%20autom%C3%A1tico%20(ML%20se,la%20precisi%C3%B3n%20de%20los%20modelos.

Aprendizaje NO supervisado

- En el aprendizaje no-supervisado los datos de entrenamiento no están etiquetados. El sistema trata de aprender una organización de los datos
    - **Clustering:** encontrar grupos de objetos o clusters donde los objetos de un mismo cluster sean similares entre sí y distintos de los objetos de otros clusters.
    - **Reducción de dimensionalidad:** reducir la cantidad de atributos de mis objetos combinando atributos redundantes o muy correlacionados (ej: el kilometraje de un auto con los años que tiene)
        - Reducir dimensionalidad se puede hacer antes de entrenar un algoritmo de ML para que funcione de forma más eficiente.

La gran limitación de estas técnicas es que son difíciles de evaluar, pues a diferencia del aprendizaje supervisado, aquí no sabemos cual es la respuesta correcta.

Clustering

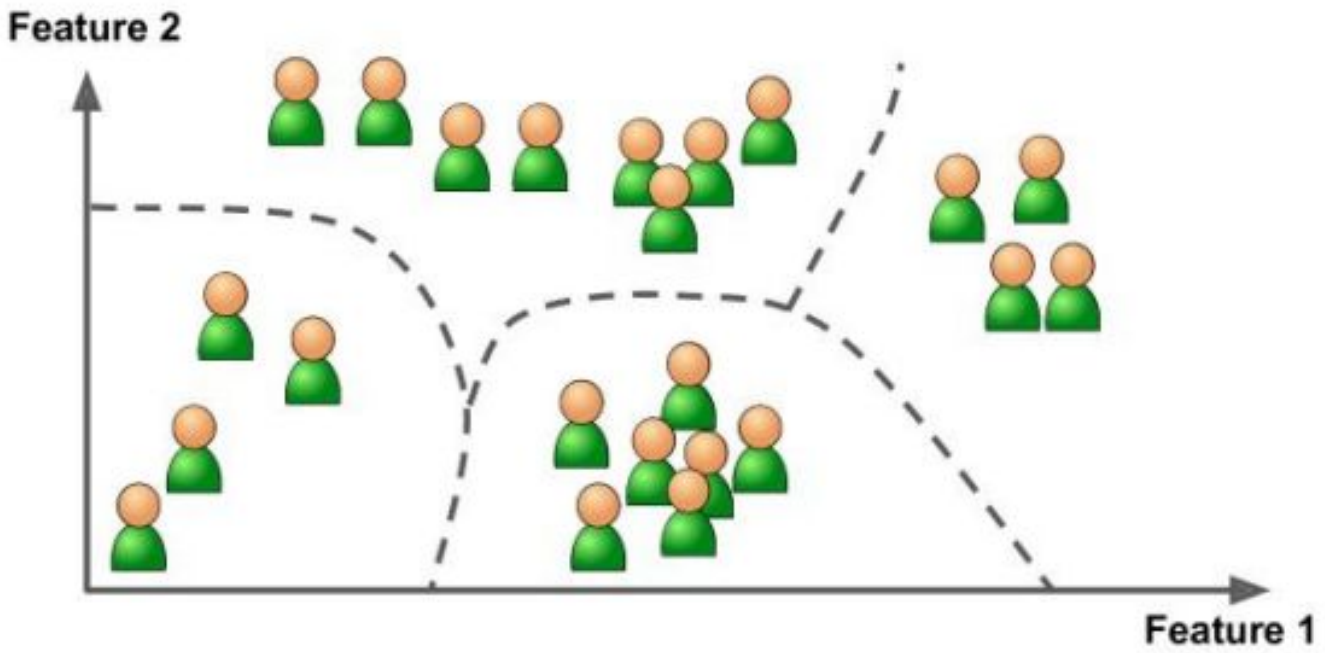

El resultado de un proceso de clustering donde se encontraron 4 clusters. Los clusters no eran conocidos antes del entrenamiento.

¿Qué es análisis de clusters?

- Técnica para encontrar grupos de objetos tal que los objetos en un grupo sean similares (o relacionados) entre sí y que sean diferentes (o no relacionados) a los objetos en otros grupos.

- Es una técnica de aprendizaje no-supervisado (no requiere etiquetas para los datos).

Un clustering es una colección de clusters

Tipos de clusterings:

- **Clustering Particional:** Divide los datos en subconjuntos sin traslape (clusters), tal que cada dato está en un solo subconjunto

- **Clustering Probabilístico o Difuso:** Cada objeto pertenece a cada cluster con un peso de pertenencia entre 0 y 1

- **Clustering Jerárquico:** Un conjunto de clusters anidados, organizados como un árbol

Métodos de clustering

- **K-means**
- **Método jerárquico aglomerativo**
- **DBSCAN**
- **Mixture of Gaussians y algoritmo EM**
- **...**

K-means

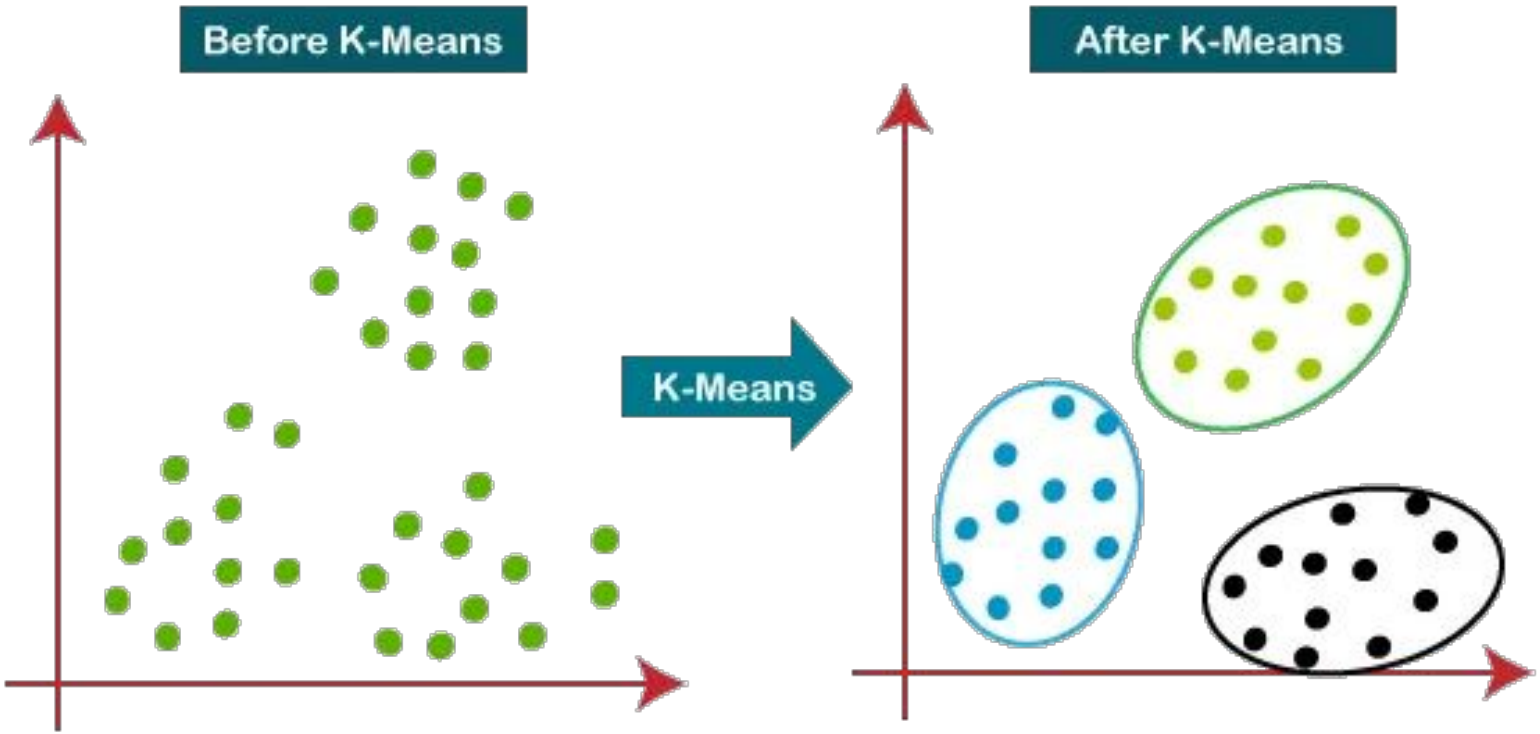
Before K-Means
K-Means
After K-Means

Paso 1: Define un k y genera k centroides de forma aleatoria

Paso 2: Calcule para cada muestra cuales es el centroide más cercano y asignele la etiqueta de que pertenece a dicho centroide

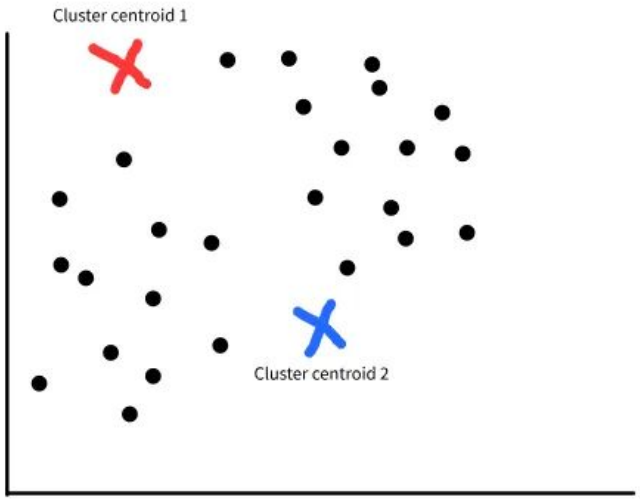

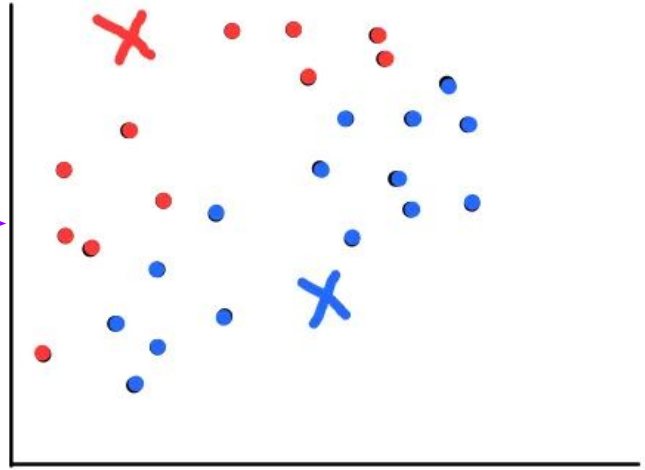

Paso 1: Define un ***k*** y genera ***k centroides*** de forma aleatoria

Paso 2: Calcule para cada muestra cuales es el centroide ***más cercano*** y asignele la etiqueta de que pertenece a dicho centroide

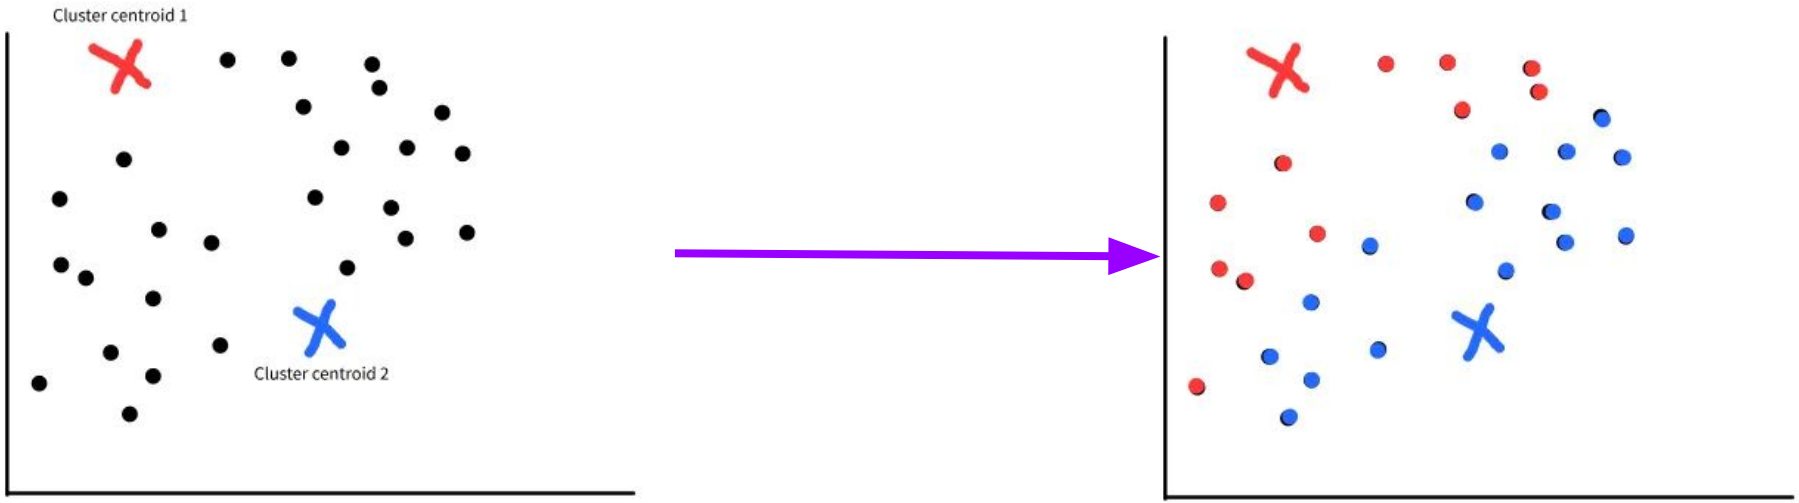

Paso 4: *Recalcule el centroide* para cada nuevo grupo

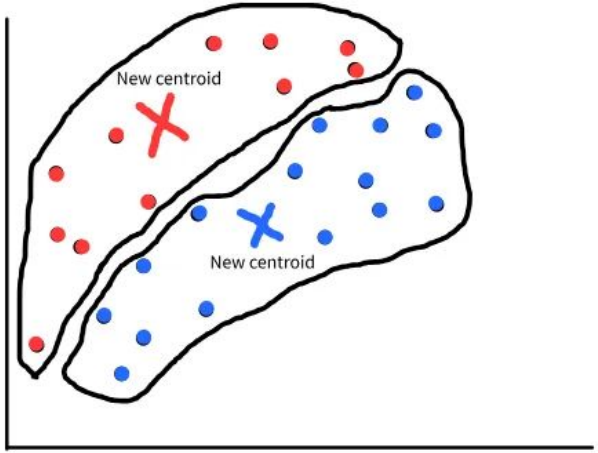

Repita el paso # 2 hasta ...

```
1. Randomly initialize the k cluster centroids
repeat{
  2. Assign the data points to cluster centroids
  3. Move cluster centroids
}
```

Ejemplo cuantización de colores en imágenes
https://github.com/dkarunakaran/kmeans_clustering/blob/master/kmeans.ipynb

Pruebe con una imágen de alguna locación en Ciénaga

Proponga una estrategia para determinar el mejor valor de k

Se pueden mejorar los resultados si se hace una selección NO aleatoria de los centroides

HW 2 - Taller grupal

Dataset
https://www.datos.gov.co/Transporte/Accidentes-de-transito-Palmira-2020/mg8y-amuh/about_data

- Utilice las columnas (hora, jornada, dia de la semana, barrio, hipótesis, clase de siniestro, clase vehículo, marca y matrícula). Preprocesar si es necesario.

- Implemente un algoritmo de k-mean y pruebe sus resultados para k = 2, 3, 4 y 5. Socialice sus resultados. (No se permite el uso de bibliotecas).

- Evalúe los resultados realizando 10, 100, 1000 iteraciones de su algoritmo.